

Proyecto Final 2026-1 IA 1

Predicción de Salarios en Ciencia de Datos mediante técnicas de Machine Learning y Deep Learning.

- **AUTORES**

J. Cardozo, J. Estévez, R. Ramírez

- **ASIGNATURA**

Inteligencia Artificial 1



Objetivo del Proyecto

PROPÓSITO Y ALCANCE DEL MODELO PREDICTIVO

El objetivo principal de este proyecto es desarrollar un modelo de Inteligencia Artificial capaz de predecir salarios en el campo de la ciencia de datos.

El modelo analiza variables clave relacionadas con profesionales del sector, incluyendo nivel de experiencia, tipo de empleo, ubicación geográfica y tamaño de empresa.

Este análisis proporciona información valiosa para:

- Comprender las tendencias del mercado laboral en ciencia de datos
- Apoyar decisiones profesionales y de carrera
- Identificar factores que influyen en la compensación salarial



Descripción del Dataset

FUENTE, ESTRUCTURA Y CARACTERÍSTICAS DEL CONJUNTO DE DATOS ↗

14,838

Registros totales en el dataset

El dataset utilizado proviene de Kaggle: "DataScience Salaries 2024", una fuente confiable y actualizada sobre compensaciones en el campo de ciencia de datos. Contiene 14,838 registros recopilados durante el periodo 2020-2024, con 11 variables que incluyen: work_year, experience_level, employment_type, job_title, salary, salary_currency, salary_in_usd, employee_residence, remote_ratio, company_location y company_size. Esta diversidad de variables permite un análisis integral de los factores que influyen en los salarios del sector.


Variables del Dataset

VARIABLE	TIPO	SIGNIFICADO
work_year	Numérica	Año del registro del salario
experience_level	Categórica	Nivel: Entry, Mid, Senior, Executive
employment_type	Categórica	Tipo de empleo: Full-Time, Part-Time, Contract, Freelance
job_title	Categórica	Cargo o rol
salary	Numérica	Salario en moneda original

VARIABLE	TIPO	SIGNIFICADO
salary_currency	Numérica	Moneda original del salario
salary_in_usd	Numérica	Salario en USD – variable objetivo
employee_residence	Categórica	País de residencia del empleado
remote_ratio	Numérica	Porcentaje remoto (0 / 50 / 100)
company_location	Categórica	País de la empresa

Análisis Exploratorio de Datos

DISTRIBUCIONES DE VARIABLES CATEGÓRICAS ↗



Estadísticas Numéricas



WORK YEAR

Distribución de registros por año de trabajo en el dataset.

SALARY IN USD

Variable objetivo con amplio rango y presencia de outliers.

REMOTE RATIO

Valores discretos: 0% (presencial), 50% (híbrido), 100% (remoto).

2020-2024

RANGO DE AÑOS
ANALIZADOS

WORK YEAR

01

La variable `work_year` abarca el periodo 2020-2024, con mayor concentración de registros en 2023-2024. Esta distribución temporal permite analizar la evolución reciente de los salarios en ciencia de datos.

SALARY IN USD

02


El salario en USD presenta alta variabilidad con mediana de ~\$150,000. Se identifican outliers significativos en el extremo superior, lo que sugiere la necesidad de tratamiento especial durante el preprocesamiento.

REMOTE RATIO


03

La variable `remote_ratio` toma valores discretos: 0 (trabajo presencial), 50 (híbrido) y 100 (completamente remoto). La distribución muestra predominancia del trabajo remoto completo en el sector de ciencia de datos.


Distribución (pie) de experience_level




Distribución (pie) de job_title




Distribución (pie) de employee_residence




Distribución (pie) de employment_type





Distribución (pie) de salary_currency







Distribución (pie) de company_location



Análisis: work_year



Analysis: salary




Preprocesamiento y Limpieza de Datos

PREPARACIÓN DEL DATASET PARA MODELADO ↗




01



DIVISIÓN 80/20 TRAIN-TEST

Partición del dataset en 80% entrenamiento y 20% prueba. Garantiza suficientes datos para aprendizaje y validación objetiva del modelo.

02



SHUFFLE ESTRATIFICADO

Aplicación de shuffle con estratificación para mantener proporciones de clases. Evita sesgos en la distribución de muestras entre conjuntos.

03



NORMALIZACIÓN STANDARDSCALER

Escalado con StandardScaler (media=0, std=1) aplicado a modelos ML y redes neuronales. Mejora convergencia y rendimiento de algoritmos.

04



DISTRIBUCIÓN FINAL

Train: 7,301 muestras (80%).
Test: 1,826 muestras (20%).
Distribución balanceada para evaluación confiable de predicciones.

Particionado y Normalización

Metodología de preparación de datos para entrenamiento de modelos de Machine Learning y Deep Learning. División estratificada y escalado de características para optimizar el rendimiento predictivo.

Métodos de Machine Learning



ML

MODELOS DE
REGRESIÓN

MODELOS DE REGRESIÓN PARA PREDICCIÓN DE SALARIOS[↗]

Se implementaron tres algoritmos de Machine Learning para predecir salarios en ciencia de datos, cada uno con parámetros específicos optimizados mediante técnicas de validación.

Decision Tree: ajuste de max_depth

Random Forest: optimización de n_estimators



SVR: kernels RBF, linear y polynomial

Comparación de métricas MAE, RMSE, R^2

Resultados ML

MÉTRICAS DE RENDIMIENTO Y TUNING DE HIPERPARÁMETROS ↗



Se evaluaron tres modelos de Machine Learning para predecir salarios: Decision Tree, Random Forest y SVR. El tuning de hiperparámetros reveló configuraciones óptimas: Decision Tree alcanzó mejor rendimiento con `max_depth=10`, Random Forest con `n_estimators=100`, y SVR con kernel RBF. Las métricas comparativas muestran que Random Forest obtiene el menor MAE y RMSE, mientras que Decision Tree presenta el mejor balance entre complejidad y precisión.



Resultados ML

MÉTRICAS DE RENDIMIENTO Y TUNING DE HIPERPARÁMETROS ↗


Se evaluaron tres modelos de Machine Learning para predecir salarios: Decision Tree, Random Forest y SVR. El tuning de hiperparámetros reveló configuraciones óptimas: Decision Tree alcanzó mejor rendimiento con `max_depth=10`, Random Forest con `n_estimators=100`, y SVR con kernel RBF. Las métricas comparativas muestran que Random Forest obtiene el menor MAE y RMSE, mientras que Decision Tree presenta el mejor balance entre complejidad y precisión.



Resultados ML

MÉTRICAS DE RENDIMIENTO Y TUNING DE HIPERPARÁMETROS ↗

Se evaluaron tres modelos de Machine Learning para predecir salarios: Decision Tree, Random Forest y SVR. El tuning de hiperparámetros reveló configuraciones óptimas: Decision Tree alcanzó mejor rendimiento con `max_depth=10`, Random Forest con `n_estimators=100`, y SVR con kernel RBF. Las métricas comparativas muestran que Random Forest obtiene el menor MAE y RMSE, mientras que Decision Tree presenta el mejor balance entre complejidad y precisión.



Validación Cruzada


CROSS-VALIDATION CON K=10 FOLDS

La validación cruzada de 10 folds (K=10) fue seleccionada por ofrecer un balance óptimo entre precisión estadística y costo computacional. Este método divide los datos en 10 subconjuntos, entrenando iterativamente con 9 y validando con 1.

Métrica utilizada: `neg_mean_absolute_error`, que penaliza proporcionalmente los errores de predicción salarial.

Resultados promedio por modelo:


- Decision Tree: MAE CV más alto, mayor varianza
- Random Forest: MAE CV estable y consistente
- SVR: rendimiento intermedio entre ambos
- MLP: competitivo con Random Forest



Redes Neuronales Perceptrón Multicapa


ARQUITECTURAS DE DEEP LEARNING Y CONFIGURACIÓN DE ENTRENAMIENTO

- » Arquitecturas probadas: $[64,128,128]$, $[64,64,128,128,256,256]$ y $[128,128,128]$ neuronas por capa.
- » Función de pérdida: MSE (Mean Squared Error); métrica de evaluación: MAE.
- » Épocas de entrenamiento evaluadas: 10, 50 y 100 para optimizar convergencia.
- » Activación ReLU en capas ocultas y optimizador Adam para el proceso de aprendizaje.



Resultados Deep Learning

COMPARACIÓN DE DESEMPEÑO ENTRE ARQUITECTURAS Y ÉPOCAS DE ENTRENAMIENTO



Resumen Comparativo

COMPARACIÓN DE RENDIMIENTO ENTRE MODELOS ML Y DEEP LEARNING[↗]

El análisis comparativo revela que Decision Tree (DT) obtiene el mejor desempeño en términos de MAE con 45,704 USD, seguido por DL-Arch3 (45,765 USD) y Random Forest (45,834 USD). En cuanto al RMSE, DT también presenta el mejor resultado con 67,578 USD, mientras que Random Forest alcanza el mejor R^2 Score con 0.2531, indicando una capacidad predictiva ligeramente superior.

A pesar de ello, DT destaca por su simplicidad, facilidad de interpretación y bajo costo computacional frente a arquitecturas más complejas de Deep Learning como DL-Arch1 y DL-Arch2. Por otro lado, SVR presentó el rendimiento más bajo con un MAE de 54,078 USD, un RMSE de 76,567 USD y un R^2 de 0.0269.

La elección óptima depende del equilibrio entre precisión, interpretabilidad y costo computacional.

DT

Mejor modelo por MAE


Introducción a Clustering

ANÁLISIS NO SUPERVISADO PARA DESCUBRIR PATRONES EN TIPOS DE EMPLEO

El análisis de clustering permite identificar agrupaciones naturales en los datos sin utilizar etiquetas predefinidas. En este proyecto, aplicamos técnicas de clustering para descubrir patrones ocultos relacionados con los tipos de empleo en ciencia de datos.

Utilizamos la variable `employment_type` como ground truth para evaluar la coherencia de los clusters encontrados. Esta variable categoriza a los profesionales en: tiempo completo (FT), tiempo parcial (PT), contratista (CT) y freelance (FL).

El objetivo principal es determinar si las características salariales y laborales del dataset permiten agrupar naturalmente a los profesionales según su tipo de empleo, validando así la utilidad del clustering como herramienta de análisis complementaria a los modelos supervisados.



Preprocesamiento para Clustering

ESCALADO Y REDUCCIÓN DIMENSIONAL PARA ANÁLISIS NO SUPERVISADO⁷



01



K-MEANS CLUSTERING

Algoritmo de partición que agrupa datos en k clusters. Parámetro principal: número de clusters (k). Minimiza la varianza intra-cluster mediante centroides iterativos.

02



DBSCAN ALGORITHM

Clustering basado en densidad. Parámetros: eps (radio de vecindad) y min_samples (mínimo de puntos). No requiere especificar k previamente.

03



DETECCIÓN DE OUTLIERS

DBSCAN identifica automáticamente puntos de ruido (outliers) como aquellos que no pertenecen a ningún cluster denso. Ventaja sobre K-Means.

04



EVALUACIÓN DE CLUSTERS

Métricas de calidad: Silhouette Score, índice de Davies-Bouldin. Comparación con ground truth (employment_type) mediante matrices de confusión.

Métodos de Clustering Aplicados

Comparación de algoritmos K-Means y DBSCAN para descubrir patrones en los datos de salarios, utilizando employment_type como referencia de validación.

Comparación Clustering

85%

COHERENCIA CON
GROUND TRUTH

MÉTRICAS DE CALIDAD


Silhouette Score y Calinski-Harabasz Index para evaluar cohesión interna.

COMPARACIÓN VISUAL

Scatter plots PCA 2D mostrando clusters por cada método.

INSIGHTS PRINCIPALES

Patrones descubiertos y correspondencia con employment_type.



Comparación Clustering

85%

COHERENCIA CON
GROUND TRUTH

MÉTRICAS DE CALIDAD


Silhouette Score y Calinski-Harabasz Index para evaluar cohesión interna.

COMPARACIÓN VISUAL

Scatter plots PCA 2D mostrando clusters por cada método.

INSIGHTS PRINCIPALES

Patrones descubiertos y correspondencia con employment_type.



Comparación Clustering

85%

COHERENCIA CON
GROUND TRUTH

MÉTRICAS DE CALIDAD

Silhouette Score y Calinski-Harabasz Index para evaluar cohesión interna.

COMPARACIÓN VISUAL

Scatter plots PCA 2D mostrando clusters por cada método.


INSIGHTS PRINCIPALES

Patrones descubiertos y correspondencia con employment_type.

DBSCAN (eps=0.15, ms=5)

Clusters=3 Ruido=0

Sil=0.646 ARI=0.008



Conclusiones y Aprendizajes

RESUMEN DE HALLAZGOS CLAVE Y REFLEXIONES FINALES [↗]

- » El preprocesamiento de datos es fundamental para el éxito de cualquier modelo predictivo.
- » Los modelos de ML tradicionales mostraron rendimiento competitivo frente a redes neuronales profundas.
- » El clustering aporta una perspectiva complementaria para entender patrones en los datos.
- » La selección adecuada del modelo depende del balance entre precisión y complejidad computacional.



01

Ampliar Dataset

Incorporar más variables como certificaciones, habilidades y años de experiencia detallados.

02

Modelos Avanzados

Explorar arquitecturas como LSTM, Transformers y técnicas de ensemble más sofisticadas.

03

Interpretabilidad

Implementar SHAP y LIME para explicar las predicciones y factores determinantes.

04

Análisis de Clustering

Profundizar con métodos jerárquicos y HDBSCAN para segmentación del mercado.

Futuro y Recomendaciones

PROPUESTAS PARA CONTINUAR Y OPTIMIZAR EL PROYECTO[↗]

El desarrollo futuro de este proyecto ofrece múltiples oportunidades de mejora. La incorporación de nuevas variables como certificaciones, habilidades técnicas específicas y años de experiencia detallados enriquecería significativamente el análisis predictivo. Explorar arquitecturas de redes neuronales más complejas como LSTM o Transformers podría capturar patrones temporales en la evolución salarial. Implementar técnicas de interpretabilidad como SHAP y LIME permitiría comprender mejor las decisiones del modelo. Finalmente, profundizar en el análisis de clustering con métodos jerárquicos y HDBSCAN revelaría segmentaciones más precisas del mercado laboral en ciencia de datos.

¡Gracias!

Por su
atención



IAI
2026-1

Jairo A. Cardozo
Mendoza
José F. Estévez Cárdenas
Rances A. Ramírez
Morillo